



Universidad Nacional de Rosario
Facultad de Ciencias Exactas, Ingeniería y Agrimensura
Tecnicatura Universitaria en Inteligencia Artificial

Procesamiento del Lenguaje Natural

Trabajo Práctico 3

Recomendador personalizado de libros

Informe

Integrantes
Franco Venesia · Marisa Zappala · Agustín Marquardt · Federico Aguirre

Docente de teoría: Juan Pablo Manson
Repositorio: federicomaguirre/procesamiento-lenguaje-natural (carpeta tp3)

Noviembre de 2026

1. Detectores de la auditoría, contaminación encontrada y costo de un falso positivo

Desarrollamos los detectores con 350 libros de la muestra etiquetada y los medimos con los 150 restantes (30 contaminados), divididos por libro con *random_state=42* y estratificación. Los fragmentos insertados eran de cuatro tipos: **enlaces visibles** (URLs, correos, WhatsApp), **enlaces disimulados** (letras separadas, «punto» y «barra» escritos con palabras, letras cirílicas y caracteres invisibles), **texto promocional sin enlace** y **mensajes en inglés o portugués**. Además había **libros inventados** que copian la sinopsis de un libro real con un autor ficticio.

Detector	Qué encuentra	Precisión	Recall
Regex (URL, correo, teléfono)	Enlaces y contactos escritos literalmente	1.00	0.50
Regex + normalización Unicode	Además, enlaces disimulados	1.00	0.63
Idioma por oración (langdetect)	Mensajes en otro idioma (mín. 10 palabras, prob. ≥ 0.90)	0.89	0.27
Clasificador de oraciones TF-IDF	Promoción con vocabulario ya visto y cadenas literales	0.94	0.97
Clasificador de oraciones embeddings	Promoción por su sentido, también en otro idioma	0.86	0.83
Libro copiado (vecino más cercano)	Libros inventados: coseno ≥ 0.75, contención ≥ 0.95, otro autor	1.00	0.10
Combinación final	**Todos los tipos**	**0.94**	**1.00**

La detección de idioma sobre la sinopsis completa no sirvió: los 70 contaminados de desarrollo salieron en español porque el mensaje es una oración entre muchas. El **NER** (spaCy) no funcionó como detector, porque las sinopsis normales también tienen entidades y en el texto publicitario el modelo se equivoca (etiqueta «compartila» como persona). Sí sirve para **explicar** una marca, porque señala el servicio promocionado (EpubMax, LetraTotal).

Combinar con «al menos uno» marcaba 625 libros del catálogo. Al revisarlos, los marcados solo por TF-IDF eran casi todos sinopsis legítimas en segunda persona (autoayuda, juveniles). Los marcados solo por embeddings incluían **mensajes nuevos que no estaban en la muestra** («Join millions of readers…», «Assine hoje e ganhe…»). La combinación final marca un libro si lo detecta la regex normalizada, si es una copia, si coinciden los dos clasificadores o si uno solo supera un umbral de alta confianza (precisión 0.98 en desarrollo), ignorando oraciones de menos de 6 palabras. El detector de idioma quedó afuera: no agregaba detecciones y sí falsos positivos. Resultado: **423 libros sospechosos (4.9 %)** y un catálogo limpio de **8152**.

Costo de un falso positivo: el libro legítimo se elimina del catálogo y nunca podrá recomendarse. Como la muestra tiene 20 % de contaminados y el catálogo mucho menos, la misma tasa de error sobre libros limpios pesa más en el catálogo: la precisión real será menor que 0.94. Por eso preferimos una combinación exigente antes que marcar todo.

2. Qué representa la etiqueta *interes* y quién valoró

interes indica si al lector **le interesaría leer** el libro, según lo que transmiten el título y la sinopsis. Es una intención previa a la lectura, no una opinión sobre el libro leído: 1 significa «me interesaría leerlo», 0 «no me interesaría» y el valor vacío significa que no pudo decidir. Un libro sin valorar tiene preferencia desconocida y no se convierte en 0.

Las valoraciones las hizo un solo integrante, **Agustín Marquardt**, antes de ver cualquier predicción. Recorrió en orden los primeros 150 libros del catálogo limpio mezclado con *random_state=42*. Resultado: **111 respuestas válidas** (56 con 1 y 55 con 0) y **39 abstenciones** (26 %), que se conservan en el CSV con *conjunto* vacío. La división 80/20 estratificada dejó 88 libros para entrenar

(44 positivos) y 23 para prueba (12 positivos).

3. TF-IDF y embeddings en las dos tareas

Tarea	Medida	TF-IDF	Embeddings
Contaminación (150 libros de prueba)	Recall a precisión ~0.90	0.97	0.83
Contaminación, mensajes nuevos	«Unite a nuestro club de lectores…»	0.22 (no marca)	0.96 (marca)
Preferencias (23 libros de prueba)	Exactitud / F1 clase 1	0.52 / 0.67	0.61 / 0.57
Preferencias, validación cruzada	F1 clase 1 (media ± desvío)	0.54 ± 0.10	0.43 ± 0.15
Preferencias, ranking	precision@5	0.40	0.80

En la auditoría la comparación es clara y estable. TF-IDF detecta mejor la contaminación de la muestra porque los dominios inventados y las frases repetidas son tokens literales con señal directa. Los embeddings **generalizan** a mensajes nuevos con el mismo sentido, incluso en otro idioma, y por eso fueron los que encontraron spam fuera de la muestra en el catálogo.

En las preferencias la diferencia es mayor, pero hay que leerla con cuidado. El F1 favorece a TF-IDF, aunque el modelo A predijo 1 para 21 de los 23 libros y sus probabilidades más altas apenas llegan a 0.55: casi no distingue. Con clases equilibradas, predecir siempre 1 daría F1 ≈ 0.69, así que ese F1 no muestra aprendizaje. Lo que sí separa a los modelos es el ordenamiento: **0.80 contra 0.40 en precision@5**. Creemos que la diferencia es mayor en esta tarea por dos razones. Los intereses del lector son **temáticos** y se expresan con vocabularios muy distintos, que TF-IDF no relaciona. Además, con 88 ejemplos TF-IDF tiene 4488 dimensiones casi vacías, mientras que los embeddings resumen cada sinopsis en 384 dimensiones que ya traen conocimiento previo del idioma.

4. ¿Algún clasificador mejoró las recomendaciones por similitud?

Lista (mismos 23 libros de prueba)	precision@5	Aciertos
Embeddings + clasificador	**0.80**	4 de 5
Azar (proporción de 1 en prueba)	0.52	—
TF-IDF + clasificador	0.40	2 de 5
Similitud con el perfil del lector	0.40	2 de 5

Sí, **el clasificador con embeddings**: superó a la similitud con el perfil (0.80 contra 0.40) y a la referencia del azar (0.52). El de TF-IDF empató con la similitud y los dos quedaron por debajo del azar. El perfil es el promedio de los embeddings de los 44 libros con interés 1 y solo usa ejemplos positivos. Un lector con gustos variados (historia, filosofía, biografías) produce un promedio que no se parece mucho a ningún tema concreto. Por eso puso primero *Cuentos de mí mismo* (similitud 0.80), que el lector había valorado con 0. La regresión logística usa también los ejemplos negativos y aprende qué direcciones del espacio separan lo que interesa de lo que no. La diferencia es de dos libros sobre cinco: es una señal favorable, no una prueba concluyente.

5. Error encontrado y límites del experimento

Error analizado. *Manual del aventurero* es un **falso negativo** del modelo B: el lector lo valoró con 1, TF-IDF predijo 1 y embeddings predijo 0. La sinopsis está escrita como un manual de consejos, con preguntas retóricas y «más de 1000 consejos y trucos». En el espacio de embeddings ese estilo queda cerca de los libros prácticos y de autoayuda, que el lector valoró con 0 en entrenamiento. TF-IDF acertó por palabras concretas (aventurero, aventuras, viajes). También encontramos un error del **resumen extractivo**. En *Eutifrón* eligió dos viñetas enumerativas («Segunda/Tercera definición…») porque comparten «justicia» y «dioses», y perdió la presentación de la obra. En *Maestros de la República* la sinopsis repite una oración y el resumen la incluyó dos veces.

Límites.

- Con 23 libros de prueba, cada libro mueve la precision@5 en 0.20 y el F1 varía mucho (desvío de 0.10 a 0.15 en validación cruzada). Las diferencias entre modelos son orientativas.
- Las preferencias son de una sola persona, expresadas a partir de sinopsis, que son textos promocionales. No sabemos si los libros le gustarían después de leerlos.
- La auditoría se midió en una muestra enriquecida que no contiene todas las variantes de contaminación. La precisión en el catálogo será menor y el recall sobre mensajes nuevos no se puede medir sin etiquetas.
- Hay 39 abstenciones (26 %), así que el modelo no aprende de los libros más ambiguos para el lector. El comentario del lector sobre las recomendaciones del paso 8 (4 de 5 le interesan) es cualitativo y no forma parte de las métricas.

Uso de asistentes de IA

Usamos asistentes de IA (Claude, de Anthropic, y Google Gemini) para entender conceptos, escribir y depurar código del notebook y revisar la redacción de los análisis. Las decisiones del procedimiento, la revisión de los resultados y las valoraciones del lector son del grupo.